

비례배분 기여도 하의 영-기여 흡수(zero-credit absorption) 진단과 최소 가상비용 처방 — tabular Monte-Carlo 포커 학습의 형식적 사례연구

[저자명]*

[소속기관] [직위]

국문 요약

표 기반 Monte-Carlo 제어로 헤즈업 노리밋 홀덤을 학습할 때, 각 행동의 보상을 그 행동의 투자액 비율로 배분하는 비례배분(proportional) 기여도 정형화는 분산을 줄이는 합리적 선택이다. 본 연구는 이 방식이 비용 0 행동(예: CHECK)에 구조적 병리를 남김을 형식적으로 보인다. 비용 0 행동의 비례 credit은 매 에피소드 정확히 0이므로 그 Monte-Carlo 고정점은 행동의 참 가치와 무관하게 0에 고정되고, 모든 가용 행동이 음(-)의 기댓값인 노드에서 이 0은 열등한 비용 0 행동을 greedy 정책이 영구히 선택하게 만든다. 우리는 이를 영-기여 흡수(zero-credit absorption, ZCA)로 명명하고 최소 toy MDP에서 (i) 영-고정점, (ii) 흡수 정리, (iii) 낙관적 초기화의 일시적 흡수와의 질적 구별(영구적 · 고정점 $\neq$ 참값)을 증명한다. 또한 무시 가능한 가상비용(virtual information cost, VIC)이 흡수를 해소함을 보이고 그 임계 가상비용을 유도하며, 통제비용로 무정보 노이즈 · 동점 처리(tie-break)가 흡수를 탈출하지 못함을 보인다. 본 결과는 학습 seed · 평가 표본과 무관한 고정점 사실이며, 실제 다단계 MDP의 성능 효과 및 분포 외(out-of-distribution) 일반화 인과는 검증되지 않은 향후 과제로 정직하게 분리한다.

주제어 : 강화학습, Monte-Carlo 제어, 기여도 배분, 보상 형성, 영-기여 흡수, tabular Q-learning, 헤즈업 노리밋 홀덤

Diagnosing Zero-Credit Absorption under Proportional Credit Assignment and a Minimal Virtual-Cost Remedy: A Formal Case Study in Tabular Monte-Carlo Poker Learning

[Author Name]*

[Affiliation], [Position]

ABSTRACT

In tabular Monte-Carlo (MC) control for heads-up no-limit Texas hold'em, assigning each action a share of the terminal payoff proportional to its invested chips—proportional credit assignment—is a reasonable variance-reduction choice. We show formally that it introduces a structural pathology for zero-cost actions (e.g., CHECK): their proportional credit is exactly zero every episode, so the MC fixed point is pinned to zero regardless of true value, and at any node where all actions have negative expected value this zero makes a greedy policy

permanently select the inferior zero-cost action. We name this zero-credit absorption (ZCA) and prove in a minimal toy MDP (i) the zero fixed point, (ii) an absorption theorem, and (iii) its qualitative distinction from the transient absorption of optimistic initialization (permanent; fixed point $\neq$ true value). We further show a negligible virtual information cost (VIC) dissolves the absorption, derive the exact threshold, and show by controlled comparison that uninformative noise and tie-breaking fail to escape it. These are fixed-point facts independent of seed and sample; the full-MDP performance effect and any link to out-of-distribution generalization are honestly separated as future work.

Keywords : reinforcement learning, Monte-Carlo control, credit assignment, reward shaping, zero-credit absorption, tabular Q-learning, heads-up no-limit hold'em

1. 서론

표 기반 강화학습은 함수근사의 블랙박스 효과 없이 학습 동역학을 단일변수로 통제 · 관찰할 수 있다. 본 연구의 무대는 헤즈업 노리밋 홀덤을 순수 tabular Monte-Carlo로 학습하는 환경이며, 목적은 강한 봇이 아니라 구조적 기여도 배분이 남기는 측정 가능한 병리의 진단이다.

Monte-Carlo 제어에서 종단 보상을 행동에 배분하는 방식은 학습 신호의 분산 · 편향을 좌우한다. 표준 Monte-Carlo는 편향이 없지만 분산이 크고, 자연스러운 대안은 각 행동이 판단에 투입한 금액의 비율로 보상을 나누는 비례배분(proportional)이다. 그러나 본 연구는 이 합리적 선택이 비용 0 행동(투자액 0, 대표적으로 CHECK)에 구조적 함정을 내포함을 보인다. 비용 0 행동의 비례 credit은 분자가 0이라 항상 0이고, 그 가치 추정의 고정점은 실제 기댓값과 무관하게 0에 고정된다. 이 0은 음의 값으로 올바르게 학습된 다른 행동들보다 높아 보여, greedy 정책이 열등한 비용 0 행동을 영구히 선택한다.

본 논문의 기여는 (1) 이 현상을 영-기여 흡수(ZCA)로 명명하고 toy MDP에서 형식적으로 증명하며, (2) ZCA가 낙관적 초기화와 고정점 수준에서 질적으로

구별됨을 보이고, (3) 무시 가능한 가상비용 VIC로 흡수를 해소하는 처방과 그 임계를 유도하며 무정보 대안과 통제비교하고, (4) 본 결과의 범위를 — 고정점 사실이되 성능 · 일반화 인과는 미검증임을 — 정직하게 분리한 것이다.

2. 관련 연구

ZCA를 이루는 부품은 인접 문헌에 모두 존재하나, 본 연구는 그 부호를 뒤집어 같은 구조를 실패 모드로 진단한다. 협력게임 이론의 Shapley value[3] 및 Shapley Q-value[4]는 null-player 공리(한계 기여 0 $\rightarrow$ 배분 0)를 공정성의 바람직한 성질로 둔다 — 본 연구의 "비용 0 $\rightarrow$ credit 0"은 그 정확한 대응물이나 진단의 방향이 반대다. 같은 직관은 difference rewards[1] · COMA[2]의 counterfactual 신용에도 깔려 있다. RUDDER[5]는 return-equivalent 재분배가 최적 정책을 보존함을 보이는데, 비례배분은 비용 0 행동에 대해 return-equivalent가 아니며 ZCA는 정확히 그 비등가 영역에서 발생한다(보존 정리의 대우). 처방 측면에서 VIC는 potential-based reward shaping(PBRS)이 Q-value 초기화와 등가[6] [7]인 틀 안에 위치한다. 다만 "비용 0(no-op) 행동에 선택적 · 음 · credit 기반 가상비용을 부여해 영-고정

흡수를 깬다"는 처방을 명시한 선행은 확인되지 않았고, 의도상 가장 가까운 action-penalty [8]는 모든 행동에 일률적이라 선택적이지 않다. 한편 미방문/낙관적 0이 음수 행동을 일시적으로 흡수하는 현상은 잘 알려져 있고 비판적 초기화의 영구 미선택도 정식화되어 있으나[9], 이는 초기화·보상값 기인으로 비례 credit이 구조적으로 0을 생성하는 본 연구의 영-기여 흡수와 기제가 다르다. 단일 seed의 결과 오도 위험은 재현성 문헌[10][11][12]이 확립했으며, 본 연구는 이를 5장에서 부정적 결과로 보고한다.

3. 영-기여 흡수의 형식적 특성화

문제 설정(toy MDP). 결정 상태 s 에서 행동 a_1 을 한 번 선택한다. 각 행동은 투자액 $\text{inv}(a_1) \geq 0$ 을 가지며 비용 0 행동(CHECK)은 $\text{inv}=0$ 이다. 선택 후 궤적은 투자액 $c>0$ 인 후속 행동을 적어도 하나 포함하고 중단 보상 P 로 끝난다($\gamma=1$, 중단 보상만). $\mu(a_1) := E[P|a_1]$ 로 두면 참값은 $q^*(s, a_1) = \mu(a_1)$ 이다. 세 배분 방식의 행동별 return $R(s, a_1)$ 은 <Table 1>과 같고, MC 업데이트 $Q \leftarrow Q + \alpha(R - Q)$ 의 고정점은 $E[R]$ 이다(sample-average 또는 감소 α ; 상수 α 도 평균 보존).

<Table 1> 행동별 return $R(s, a_1)$ / Per-action return

방식 (scheme)	$R(s, a_1)$
표준 MC	P
비례배분 (PROP)	$[\text{inv}(a_1) / (\text{inv}(a_1) + c)] \cdot P$
VIC	PROP과 동일, 단 $\text{inv}(\text{CHECK}) \leftarrow \varepsilon > 0$

Lemma 1 (표준 MC의 일치성). $Q_{\text{std}}(s, a_1) \rightarrow \mu(a_1) = q^*(s, a_1)$. 증명. $R=P$ 이므로 고정점은 $E[P|a_1] = \mu(a_1)$. ■

Lemma 2 (비용 0 행동의 영-고정점). $Q_{\text{prop}}(s, a_1) = [\text{inv}(a_1) / (\text{inv}(a_1) + c)] \cdot \mu(a_1)$, 특히 $Q_{\text{prop}}(s, \text{CHECK}) = (0/(0+c)) \cdot \mu(\text{CHECK}) = 0$ ($\forall \mu(\text{CHECK})$). 증명. CHECK는 분자가 0. ■ CHECK의 고정점은 참값과 무관하게 0이며, $R=0$ 이라 표본 분산도 0인 구조적 고정점(초기화 잔재 아님)이다. 비용>0 행동은 $\mu(a_1)$ 을 $\text{inv}/(\text{inv}+c) < 1$ 로 수축하되 부호를 보존한다 — 이 비대칭이 ZCA의 핵심이다.

Theorem (영-고정점에 의한 흡수). $q^*(\text{CHECK}) = \mu_C < \mu_B = q^*(\text{BET})$ 이고 $\mu_B < 0$ 이면 (BET이 낮지만 둘 다 $-EV$), 비례배분 greedy는 열등한 CHECK를, 표준 MC greedy는 최적 BET을 선택한다. 증명. $Q_{\text{prop}}(\text{CHECK})=0 > [b/(b+c)] \cdot \mu_B = Q_{\text{prop}}(\text{BET})$ 이나 $\mu_C < \mu_B$ 이므로 CHECK는 열등. 표준 MC는 $Q = \mu$ 이므로 BET 선택. ■

흡수의 적용 범위(중요). 흡수는 덜 나쁜 대안조차 $-EV$ 일 때만 발생한다. 어떤 행동이 $+EV$ 이면 $Q_{\text{prop}} > 0 = Q_{\text{prop}}(\text{CHECK})$ 라 정상 선택되므로, ZCA가 손상시키는 것은 "모든 가용 행동이 $-EV$ 인 노드에서 덜 나쁜 것을 고르는 능력"뿐이다.

Proposition 1 (낙관적 초기화와의 구분). Q 를 0으로 초기화한 표준 MC에서 미방문 행동의 0-선택은 충분한 방문 후 $Q \rightarrow \mu$ 로 소거되어 일시적이며 고정점은 참값이다(Lemma 1). 대조적으로 $Q_{\text{prop}}(\text{CHECK})=0$ 은 수렴 후에도 유지되는 고정점이며 참값과 다르다(Lemma 2). 즉 표면("0이 음수를 흡수")은 같으나 낙관적 초기화는 "아직 학습 못 해서"(일시적, 고정점=참값), ZCA는 "구조적으로 학습 불가라서"(영구, 고정점=0≠참값)이다. 이 고정점의 차이가 본 진단의 핵심이다.

4. VIC: 임계 가상비용과 탈출 메커니즘 비교

Proposition 2 (VIC 복원과 임계). CHECK에 가상 투자 $\varepsilon > 0$ 을 주면 $Q_{vic}(CHECK) = [\varepsilon / (\varepsilon + c)] \cdot \mu_C$ 이다. Theorem 설정에서 greedy가 BET을 선택할 필요충분조건은 $[b/(b+c)] \cdot \mu_B > [\varepsilon / (\varepsilon + c)] \cdot \mu_C$ 이고, $\mu_C < 0$ 이므로 $k := [b/(b+c)] \cdot (\mu_B / \mu_C) \in (0, 1)$ 에 대해 $\varepsilon > \varepsilon_{min} = k \cdot c / (1 - k)$. ε 이 임계를 넘으면 $Q_{vic}(CHECK)$ 가 음으로 내려가 복원되고, 너무 작으면 흡수가 잔존한다. ε_{min} 은 일반적으로 작아 "무시할 1칩이 임계만 넘으면 충분"하다는 설계와 정합한다. 핵심은 VIC가 부여하는 값이 참값 μ_C 에 연동(informed)된다는 점이다.

탈출 메커니즘 통제비교(<Table 2>). 비례배분 위에 VIC, 무정보 노이즈(결정 시 $N(0, \sigma^2)$ 가산), tie-break(정확히 동률일 때만 CHECK 후순위), 고정 페널티($-\kappa$)를 얹어 비교한다.

<Table 2> 탈출 메커니즘 비교 / Escape-mechanism comparison ($\mu_C = -5$, $\mu_B = -1$, $b = c = 1$)

메커니즘 (mechanism)	Q(CHECK)	Q(BET)	P(pick BET)	판정
표준 MC (대조)	-5.0	-1.0	1.00	ZCA 없음
비례배분 (ZCA)	0.0	-0.5	0.00	흡수
VIC ($\varepsilon = 1$)	-2.5	-0.5	1.00	복원 · informed
노이즈 ($\sigma = 1$)	0.0	-0.5	0.36	미복원
tie-break	0.0	-0.5	0.00	미복원
고정 페널티 ($\kappa = 1$)	-1.0	-0.5	1.00	복원 · 무정보

두 가지가 갈린다. 첫째, strict 흡수 발동. ZCA는 $0 > Q(BET) < 0$ 인 부등식이지만 동률이 아니므로, "동률일 때만" 작동하는 tie-break은 미발동($0 \neq -0.5$)이며 흡수가 잔존한다. 노이즈도 고정점 0이 -0.5 보다 높아 결정 시 잡음을 줘도 열등 CHECK를 약 64% 선택한다(학습 중 zero-mean 노이즈도 MC 고정점을 안 바꿔 동일). 즉 tie-break · 노이즈는 strict 흡수를 탈출하지 못한다. 둘째, informed 여부. VIC와 고정 페널티는 복원하나, VIC의 고정점은 μ_C 에 연동(informed)되어 서로 다른 μ_C 의 다중 비용 0 상태에 자동 적응하는 반면 고정 페널티 $-\kappa$ 는 무정보다. 단 이 적응 이점의 성능 유의성은 실제 MDP 통제비교가 필요한 별도 문제다. 결국 VIC만 "strict 흡수 해소 + 고정점 informed"를 동시 충족한다.

5. 수치 검증과 한계

검증. <Table 1> · <Table 2>의 모든 주장을 독립 Monte-Carlo 시뮬레이션(40만 에피소드)으로 검증하였고 결과는 <Table 3> 및 해석식과 일치한다. 특히 비례배분에서 $Q(CHECK) = 0.000$ ($\neq \mu_C = -5$)으로 흡수가, VIC에서 -2.50 으로 복원이 재현된다. 임계도 $\varepsilon_{min} = 0.111$ 에서 $\varepsilon \leq 0.111 \rightarrow CHECK$ · $\varepsilon > 0.111 \rightarrow BET$ 으로 소수점까지 일치한다. 검증 코드는 공개한다.

<Table 3> 수치 검증 / Numerical verification (40만 ep, $b = c = 1$, $\mu_C = -5$, $\mu_B = -1$, $\varepsilon = 1$)

방식	Q(CHECK)	Q(BET)	greedy	판정
표준 MC	-4.99 ($\approx \mu_C$)	-1.00	BET	정상(최적)
비례배분	0.000 ($\neq \mu_C$)	-0.50	CHECK	흡수(열등)
VIC	-2.50	-0.50	BET	복원

범위와 한계(정적). (1) 본 결과는 학습 seed · 평가 표본과 무관한 고정점 사실이다. 실제 2,048-셀 MDP에서는 c가 궤적마다 변하나 핵심(비용 0의 구조적 0-credit)은 동일하다. (2) 본 정리는 ZCA의 존재 · 특성화이지 VIC의 성능 · 일반화 인과가 아니다. 예비 실험에서 VIC 제거가 미학습 상대 대상 선택적 저하를 보였으나 학습 seed 전반의 통제실험에서 재현되지 않았다 — 따라서 "VIC=분포 일반화의 필요조건"이라는 강한 주장은 지지하지 않으며, 단일 seed 오도 가능성 [10] [11] [12]과 정합하는 부정적 결과로 보고한다. 비용 0의 영-고정점(seed 무관)과 OOD 성능(seed 의존)은 별개 층위다. (3) VIC는 임계 이상이면 작동하는 한 처방이며 유일 · 최선이 아니다(4장의 고정 페널티 대비 성능 우열은 미검증). (4) ZCA의 부품은 알려져 있고 VIC는 $PBRs=Q-init$ [7] 틀 안에 있어 알고리즘 신규성은 제한적이다 — 기여는 알려진 구조의 미보고 실패 모드를 명명 · 형식화하고 임계를 유도하며 범위를 정칙히 분리한 데 있다. (5) 단일 추상화 · 단일 게임에 한정된다.

6. 결론

본 연구는 tabular Monte-Carlo 비례배분 기여도가 비용 0 행동에 남기는 구조적 병리를 영-기여 흡수(ZCA)로 명명하고, toy MDP에서 영-고정점과 흡수를 증명하였다. ZCA는 낙관적 초기화와 고정점 수준에서 질적으로 구별되며, 최소 가상비용 VIC가 명시적 임계 이상에서 이를 해소함을, 그리고 무정보 노이즈 · tie-break은 strict 흡수를 탈출하지 못함을 보였다. 이 결과들은 seed · 표본과 무관한 형식적 사실이며, 실제 다단계 MDP의 성능 효과와 분포 외 일반화 인과는 향후 과제로 분리하였다. 본 사례연구의 가치는 성능이 아니라 구조적 기여도 배분의 측정 가능한 병리를 형식적으로 진단하고 한계를 정칙하게 드러낸 데 있다.

참고문헌

- [1] D. H. Wolpert and K. Tumer, "Optimal payoff functions for members of collectives," *Advances in Complex Systems*, Vol. 4, No. 2/3, pp. 265–279, 2001.
- [2] J. Foerster, G. Farquhar, T. Afouras, N. Nardelli, and S. Whiteson, "Counterfactual multi-agent policy gradients," *Proc. AAAI Conf. on Artificial Intelligence*, pp. 2974–2982, 2018.
- [3] L. S. Shapley, "A value for n-person games," *Contributions to the Theory of Games II*, Princeton Univ. Press, pp. 307–317, 1953.
- [4] J. Wang, Y. Zhang, T.-K. Kim, and Y. Gu, "Shapley Q-value: A local reward approach to solve global reward games," *Proc. AAAI Conf. on Artificial Intelligence*, pp. 7285–7292, 2020.
- [5] J. A. Arjona-Medina, M. Gillhofer, M. Widrich, T. Unterthiner, J. Brandstetter, and S. Hochreiter, "RUDDER: Return decomposition for delayed rewards," *Advances in Neural Information Processing Systems*, pp. 13544–13555, 2019.
- [6] A. Y. Ng, D. Harada, and S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," *Proc. Int. Conf. on Machine Learning*, pp. 278–287, 1999.
- [7] E. Wiewiora, "Potential-based shaping and Q-value initialization are equivalent," *Journal of Artificial Intelligence Research*, Vol. 19, pp. 205–208, 2003.
- [8] S. Koenig and R. G. Simmons, "The effect of representation and knowledge on goal-directed exploration with reinforcement-learning algorithms," *Machine Learning*, Vol. 22, pp. 227–250, 1996.
- [9] T. Rashid, B. Peng, W. Boehmer, and S. Whiteson, "Optimistic exploration even with a pessimistic initialisation," *Proc. Int. Conf. on Learning Representations*, 2020.

- [10] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, "Deep reinforcement learning that matters," Proc. AAAI Conf. on Artificial Intelligence, pp. 3207–3214, 2018.
- [11] C. Colas, O. Sigaud, and P.-Y. Oudeyer, "How many random seeds? Statistical power analysis in deep reinforcement learning experiments," arXiv:1806.08295, 2018.
- [12] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," Advances in Neural Information Processing Systems, pp. 29304–29320, 2021.
- [13] J. Kim, "PokerKit: A comprehensive Python library for fine-grained multi-variant poker game simulations," IEEE Trans. on Games, 2023.
- [14] R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed., MIT Press, 2018.

저자소개

[저자명] (Author Name) [정회원]

[학사/석사/박사 취득연월 및 학위명]

[현 소속기관 및 직위] E-mail : [e-mail]

관심분야 : 강화학습, 게임 AI, 학습 동역학 분석