

27번 실험 — 강화학습 환경 설계

혼합/순환 페르소나 학습을 통한 분포 강건성 (Heads-Up No-Limit Texas Hold'em) · PPT 발표용 정리 자료

한 줄 요약 — "2,048셀 이산 상태 × 8행동 / 몬테카를로 비례배분 보상 / Softmax 탐색" 위에서, 학습 상대를 5종 페르소나 혼합으로 다양화해 단일 상대 과적합을 깨고 분포 강건성을 입증한 실험.

0. 게임 환경

- 엔진: `pokerkit` No-Limit Texas Hold'em, 헤즈업(2인) 구조
- 스택 / 블라인드: 시작 스택 200, 빅블라인드 2, 스몰블라인드 1 → 한 핸드당 **100 BB** 깊이
- 매 에피소드 = 1 핸드 (딜 → 베팅라운드 → 쇼다운/폴드까지)

1. 상태 (s) — 4차원 추상화

연속적인 포커 상황을 **2,048개 셀**로 이산화한다.

차원	크기	내용
Round	4	PREFLOP / FLOP / TURN / RIVER
Position	2	BB(player 0) / SB(player 1)
State (핸드강도)	8	PREMIUM→TRASH. 프리플랍은 Chen score, 포스트플랍은 treys 평가(7462 백분위)로 버킷팅
PrevAction	4	같은 라운드 내 상대의 직전 액션 압축: NONE / CHECK_CALL / SMALL_RAISE / BIG_RAISE

$$q[\text{round}][\text{position}][\text{state}][\text{prev_action}][\text{action}] = 4 \times 2 \times 8 \times 4 \times 8 = 2,048 \text{ 셀}$$

PrevAction 축이 핵심 — "상대가 큰 레이즈를 던졌는가"를 상태에 넣어 **상대 행동에 조건부로 반응**할 수 있게 한다.

2. 행동 (a) — 8종

`FOLD, CHECK, CALL, RAISE_25, RAISE_50, RAISE_75, RAISE_100, RAISE_ALLIN` (팟 대비 비율 베팅).

매 결정 시 `legal_our_actions()` 로 합법 액션만 후보로 추린다.

3. 보상 (r) 과 리턴 (g) — 핵심 설계

최종 보상 **r (terminal-only)**

$$r = \text{payoff} = (\text{최종 스택}) - (\text{시작 스택})$$

중간 스텝에는 보상이 없고, 핸드 종료 시 **순손익(칩)** 하나만 발생한다.

리턴 g — 비례 배분 (proportional credit assignment)

$$g_i = (\text{invest}_i / \sum_j \text{invest}_j) \times \text{payoff}$$

- 크게 베팅한 결정일수록 그 핸드 결과에 대한 책임(credit)을 더 많이 받음
- 투입이 0인 경우(전원 CHECK)는 payoff를 스텝 수로 균등 분배
- **CHECK_VIRTUAL_INVEST = 1 chip**: CHECK도 투입 0이 아닌 1칩으로 간주 → CHECK 라인이 credit 0으로 흡수되어 학습이 고착되는 'CHECK=0 고정점' 문제 방지

4. 보상 전파 경로 — 몬테카를로 (MC)

에피소드 종료 후 일괄 업데이트 (부트스트래핑 없음):

$$Q(s, a) \leftarrow Q(s, a) + \alpha \cdot [g - Q(s, a)]$$

1 핸드 플레이 → trace에 (round, state, prevAction, action, invest) 누적
 ↓ 핸드 종료
 payoff 확정 → invest 비율로 g 배분
 ↓
 trace의 모든 스텝에 $\text{update_mc}(g)$ 적용

왜 MC인가? TD의 maximization bias(낙관적 과대평가)가 포커의 분산 큰 보상에서 학습을 망가뜨린다. MC는 실제 핸드 결과만 평균내므로 그 편향이 없다. (**GAMMA=0.9** 는 TD 경로 전용으로, MC 경로에선 미사용)

5. 학습 데이터 — 핵심 설계

고정된 알고리즘·하이퍼파라미터 위에서 **매 에피소드 학습 상대 policy만 교체**한다. 다른 변수를 모두 고정했기에 "상대 분포 다양화"의 효과만 분리해 측정하는 controlled comparison이 된다.

학습 상대 = 5종 룰베이스 페르소나

페르소나	성향	역할
TAG	Tight-Aggressive	정석 대조군 (= 평가 상대)
LAG	Loose-Aggressive	넓은 레이즈 → 베팅 직면 셀 도달
MAN	Maniac	거의 전부 레이즈 → BIG_RAISE 컨텍스트 공급
STA	Calling Station	콜다운 → 깊은 라운드 도달
NIT	Rock	프리미엄만 플레이 → FOLD=정답 케이스

두 가지 혼합 스킴

스킴	방식	의도
cycle	에피소드 인덱스로 결정론적 순환 ($ep \% 5$), 각 정확히 1/5	균등 · 재현성 보장
mixed	매 에피소드 가중 샘플링 [tag .20 / lag .25 / man .15 / sta .25 / nit .15]	적자 유발 성향(lag-sta) 가중 ↑로 병목 직격

- **설계 동기**: 단일 상대로만 학습하면 그 상대에만 특화(과적합)되어 일반 상대(Random)에 적자가 난다. 여러 전이분포를 섞어 경험시키면 분포 강건성이 생긴다는 가설(H1).
- `learner_id = i % 2` 로 매 에피소드 **포지션(BB/SB) 교대** → 양 포지션 균등 학습.

6. 평가 데이터 — 학습과 분리

평가는 탐색을 끈 **raw greedy**(`best_action` , $\text{argmax } Q$)로 수행.

- **평가 상대 2종**: ① 순수 Random ② 고정 TAG 룰베이스 (학습 상대와 분리해 일반화 측정)
- **규모**: 정밀 평가 100,000 games × **5회 반복**(seed 1000~1004)으로 회차 SD 추정
- **지표**: `mbb/g` (milli-big-blinds per game) — 승률이 아닌 **수익률**. $mbb = \text{평균 payoff} \times (1000 / BB)$
- **판정 기준(사전 등록)**: `평균 - 1·회차SD > 0` 이 vs Random·vs TAG **양쪽 모두** 성립해야 H1 채택

승률 대신 mbb/g를 쓰는 이유: 승률이 높아도 큰 팻을 잃으면 실제 수익은 적자일 수 있어(포커의 큰 분산 특성), **mbb/g 양수 전환만을 학습 성공의 증거로 삼는다**.

27번 결과

run	vs Random (mbb/g, 회차SD)	vs 고정 TAG (mbb/g, 회차SD)	판정
cycle	+681.3 (51.4)	+868.3 (12.1)	동시 흑자 ✅

mixed	+1083.9 (110.5)	+885.2 (10.9)	동시 흑자 
-------	-----------------	---------------	---

두 독립 스킴(cycle/mixed) 모두 vs Random·vs TAG 양쪽에서 **동시 흑자** → 분포 강건성 달성. 평균-3·회차SD까지 전부 양수로 부호 안정.

7. 하이퍼파라미터

항목	값
학습률 α	0.1
γ (MC 미사용)	0.9
총 에피소드	2,000,000
온도 스케줄	10.0 → 0.5, 전체 80% 구간 선형 감소 후 유지
seed	42
학습 중 평가 주기	8,000 ep (모니터링용)

8. 탐색 함수 — Softmax (Boltzmann)

학습 중 행동 선택은 온도 기반 **Softmax**:

$$P(a) = \exp(Q(a) / \tau) / \sum_{a'} \exp(Q(a') / \tau)$$

- 초반 고온($\tau=10$) → 거의 균등 샘플링(탐색), 후반 저온($\tau=0.5$) → 거의 greedy(활용)
- ϵ -greedy와 달리 **Q값에 비례한 확률적 탐색** → 유망한 액션을 더 자주, 나쁜 액션도 가끔 시도
- 수치 안정화를 위해 max_q를 빼고 지수화, 오버플로 시 greedy로 폴백
- 탐색 함수로는 Softmax를 사용 (UCB 계열은 탐색이 학습을 잠식하는 경향이 있어 제외)

9. 전체 학습 루프 요약

```

for episode in 1 .. 2,000,000:
     $\tau$       = temperature_at(episode)           # 10.0 → 0.5
    상대    = pick_persona(scheme, episode)     # cycle 순환 / mixed 가중샘플링
    pos     = episode % 2                       # BB/SB 포지션 교대
    ┌ 1 핸드 플레이 ───────────────────────────┐
    │ 학습자 차례: a = softmax_action(s,  $\tau$ ) → trace 누적 │
    │ 상대 차례 : 페르소나 policy 로 행동 │
    └ 핸드 종료 → payoff 확정 │
    g 배분(invest 비율) → 모든 스텝 update_mc(g)

every 8,000 ep: raw-greedy 로 vs Random / vs TAG 평가 기록

```

출처: poker-pokerkit-prev/train_softmax_persona_mixed_2000k.py, train_softmax_persona_2000k.py, qlearning.py, abstraction.py, train_eval_mc_prop_softmax_2000k.py, rulebased_personas.py · 실험일지.md 23~24절